

GPT-Etiketli Fake News Sınıflandırmasında BERT-like Modellerin Yeniden Üretimi ve Precision-Recall Tradeoff Analizi

Nisanur Genç

Abstract (Özet)

Fake news detection, dijital haber ortamlarında yanlış bilginin yayılımını azaltmak amacıyla ele alınan önemli bir Natural Language Processing (NLP) problemidir. Bu çalışmada, Raza, Paulen-Patterson ve Ding tarafından önerilen BERT-like modeller ve Large Language Models (LLMs) karşılaştırmasını temel alan bir fake news classification pipeline yeniden uygulanmış ve elde edilen bulgular doğrultusunda model performansını iyileştirmeye yönelik kontrollü deneyler gerçekleştirilmiştir. Çalışmada, yazarların GitHub reposu üzerinden yönlendirilen newsmediabias/NELA-GT_GPT-Labels_Dataset veri seti kullanılmış; title ve content alanları birleştirilerek model girdisi oluşturulmuş ve hedef değişken olarak gpt label seçilmiştir.

İlk deneylerde DistilBERT, RoBERTa ve weighted loss uygulanmış DistilBERT modelleri değerlendirilmiştir. En yüksek test F1-score değeri 0.5679 ile DistilBERT baseline modelinde elde edilmiştir. Veri setindeki belirgin class imbalance nedeniyle özellikle minority class recall değerinin sınırlı kaldığı gözlemlenmiş; bu nedenle threshold tuning, mild weighted loss, epoch artırma, learning rate düşürme ve BERT-base architecture comparison deneyleri uygulanmıştır. Sonuçlar, bu geliştirme stratejilerinin farklı metriklerde iyileşme sağladığını ancak test F1-score bakımından DistilBERT baseline sonucunu aşamadığını göstermiştir. En yüksek test accuracy BERT-base modelinde (0.8727), en yüksek test recall ise aggressive weighted loss yaklaşımında (0.6465) elde edilmiştir.

Bulgular, GPT-labeled fake news classification probleminde performansın yalnızca model mimarisine bağlı olmadığını; class imbalance, threshold selection, training configuration ve precision-recall tradeoff gibi faktörlerin model davranışı üzerinde belirleyici olduğunu göstermektedir.

Anahtar Kelimeler: fake news detection, BERT, DistilBERT, RoBERTa, BERT-base, class imbalance, weighted loss, threshold tuning, precision-recall tradeoff

1. Introduction (Giriş)

Dijital haber platformları ve sosyal medya kanalları, haber içeriklerinin çok hızlı biçimde üretilmesini ve geniş kitlelere ulaşmasını sağlamaktadır. Ancak bu hız, yanlış veya yanıltıcı bilginin yayılımını da kolaylaştırmaktadır. Bu nedenle fake news detection, günümüzde hem akademik hem de pratik açıdan önemli bir Natural Language Processing (NLP) problemi haline gelmiştir. Fake news detection görevi, bir haber metninin gerçek (real) veya sahte (fake) olarak sınıflandırılmasını amaçlayan bir binary text classification problemidir [1], [2].

Son yıllarda bu problem için transformer tabanlı modeller yaygın olarak kullanılmaktadır. Özellikle BERT, DistilBERT ve RoBERTa gibi BERT-like encoder-only modeller, metin sınıflandırma görevlerinde güçlü bağlamsal temsil üretme kapasiteleri nedeniyle öne çıkmaktadır [5], [6], [7].

Bunun yanında, Large Language Models (LLMs) de zero-shot, few-shot ve fine-tuning yaklaşımlarıyla fake news detection problemlerinde değerlendirilmektedir. Raza, Paulen-Patterson ve Ding tarafından yapılan çalışmada, BERT-like modeller ile LLM'ler GPT ile etiketlenmiş fake news verisi üzerinde karşılaştırmalı olarak incelenmiş ve model performansları farklı metrikler üzerinden raporlanmıştır [13].

Bu çalışma, söz konusu araştırmayı temel alarak GPT-labeled fake news sınıflandırması için yeniden üretilebilir bir classification pipeline kurmayı ve elde edilen sonuçlar üzerinden model performansını etkileyen faktörleri analiz etmeyi amaçlamaktadır. Çalışmada kullanılan veri seti, ilgili çalışmanın GitHub reposu üzerinden yönlendirilen newsmediabias/NELA-GT_GPT-Labels_Dataset veri setidir. Veri setinde haber başlığı (title), haber içeriği (content), nela label ve gpt label alanları bulunmaktadır. Bu çalışmada hedef değişken olarak gpt label kullanılmıştır.

Erişilen veri seti 5414 örnekten oluşmakta ve sınıf dağılımı açısından belirgin bir class imbalance problemi içermektedir. Bu dengesizlik, özellikle minority class örneklerinin doğru yakalanmasını zorlaştırmakta ve recall ile F1-score değerleri üzerinde doğrudan etki oluşturmaktadır. İlk deneylerde DistilBERT, RoBERTa ve weighted loss uygulanmış DistilBERT modelleri değerlendirilmiş; DistilBERT baseline modeli test F1-score bakımından en dengeli sonucu vermiştir. Buna karşılık weighted loss yaklaşımı recall değerini artırmış, ancak precision ve accuracy üzerinde düşüşe neden olmuştur.

Bu bulgulardan hareketle çalışmada, model performansını geliştirmeye yönelik kontrollü deneyler gerçekleştirilmiştir. Bu kapsamda threshold tuning, mild weighted loss, epoch artırma, learning rate düşürme ve BERT-base architecture comparison yöntemleri test edilmiştir. Amaç yalnızca farklı modeller veya parametreler denemek değil; veri setinde gözlenen class imbalance ve precision-recall tradeoff problemlerinin model davranışı üzerindeki etkisini analiz etmektir.

Bu çalışmanın temel katkıları aşağıdaki şekilde özetlenebilir:

- GPT-labeled fake news veri seti üzerinde BERT-like modeller için yeniden üretilebilir bir classification pipeline kurulmuştur.
- DistilBERT, RoBERTa ve BERT-base modellerinin aynı veri bölünmesi üzerinde karşılaştırmalı performans analizi yapılmıştır.
- Class imbalance problemine karşı weighted loss, mild weighted loss ve threshold tuning yaklaşımlarının etkisi incelenmiştir.
- Epoch sayısı ve learning rate değişikliklerinin model performansına etkisi değerlendirilmiştir.
- Geliştirme deneylerinin accuracy, precision, recall ve F1-score üzerindeki etkileri ayrı ayrı analiz edilmiştir.
- Orijinal çalışmadaki performans düzeylerine ulaşamamasının olası nedenleri; veri seti sürümü, örnek sayısı, donanım kapasitesi, preprocessing farkları ve hiperparametre belirsizlikleri açısından tartışılmıştır.

Makalenin geri kalan bölümleri şu şekilde düzenlenmiştir: Related Work bölümünde fake news detection, transformer tabanlı sınıflandırma ve class imbalance yaklaşımlarına ilişkin çalışmalar özetlenmektedir. Material and Methods bölümünde veri seti, preprocessing adımları, model mimarileri ve deneysel kurulum açıklanmaktadır. Experimental Results bölümünde elde edilen sonuçlar tablo ve grafiklerle sunulmaktadır. Discussion bölümünde sonuçlar yorumlanmakta ve orijinal çalışma ile farklar analiz edilmektedir. Conclusion bölümünde ise çalışmanın temel bulguları ve gelecek çalışma önerileri özetlenmektedir.

2. Related Work (Literatür Taraması)

Bu bölümde fake news detection literatürü dört eksen üzerinden ele alınmaktadır: geleneksel ve transformer tabanlı yaklaşımlar, BERT-like modeller ile LLM karşılaştırmaları, GPT destekli etiketleme süreçleri ve class imbalance problemini ele alan yöntemler.

2.1 Fake News Detection ve Transformer Tabanlı Yaklaşımlar

Fake news detection, dijital ortamlarda yayılan yanlış veya yanıltıcı haber içeriklerinin otomatik olarak tespit edilmesini amaçlayan önemli bir Natural Language Processing (NLP) problemidir. Literatürde fake news kavramı yalnızca tamamen uydurulmuş haberleri değil; yanıltıcı başlıklar, bağlamından koparılmış bilgiler, kasıtlı dezenformasyon, yanlış yönlendiren içerikler, clickbait ve manipülatif haber sunumları gibi farklı türleri de kapsamaktadır. Bu nedenle fake news detection problemi, çoğu çalışmada bir binary text classification görevi olarak ele alınsa da pratikte veri kalitesi, etiket güvenilirliği, haber kaynağı, içerik özellikleri ve sosyal bağlam gibi birçok faktörden etkilenmektedir [1], [2].

Fake news detection alanındaki erken dönem çalışmalar, çoğunlukla geleneksel makine öğrenmesi yöntemlerine ve el ile çıkarılmış metinsel özelliklere dayanmıştır. Bu çalışmalarda TF-IDF, Bag-of-Words, sözcük frekansları, stilistik göstergeler ve duygu analizi gibi temsil yöntemleri; Support Vector Machine (SVM), Logistic Regression, Naive Bayes, Random Forest ve benzeri sınıflandırıcılarla birlikte kullanılmıştır. Rashkin vd. [3], haber dilindeki stilistik farklılıkları inceleyerek güvenilir ve güvenilir olmayan haber içeriklerinin dilsel örüntüler üzerinden ayrıştırılabileceğini göstermiştir. Bu tür yöntemler düşük hesaplama maliyeti ve yorumlanabilirlik açısından avantaj sağlasa da, haber metinlerindeki bağlamsal ilişkileri, uzun metin bağımlılıklarını ve örtük anlam ilişkilerini yakalamakta sınırlı kalabilmektedir.

Bu sınırlılıklar, derin öğrenme tabanlı yaklaşımların fake news detection alanında daha fazla kullanılmasına yol açmıştır. LSTM, BiLSTM, CNN ve attention tabanlı modeller, geleneksel yöntemlere kıyasla daha zengin metin temsilleri üretebilmiş; ancak özellikle uzun haber metinlerinde ve bağlama duyarlı anlam farklılıklarında her zaman yeterli performans gösterememiştir. Transformer mimarisinin ortaya çıkmasıyla birlikte, self-attention mekanizması sayesinde metin içerisindeki token'lar arasındaki ilişkiler daha etkili biçimde modellenenebilir hale gelmiştir [4]. Bu gelişme, haber metinleri gibi uzun ve bağlamsal olarak karmaşık içeriklerin sınıflandırılmasında önemli bir dönüm noktası oluşturmuştur.

Transformer tabanlı ön-eğitilmiş dil modelleri, fake news detection alanında özellikle BERT-like encoder-only modeller üzerinden yaygınlaşmıştır. BERT, çift yönlü bağlamsal ön-eğitim yapısı sayesinde metindeki hem sol hem de sağ bağlamı birlikte dikkate alarak güçlü temsil vektörleri üretmektedir [5]. RoBERTa, BERT mimarisinin eğitim stratejilerini optimize ederek daha güçlü bir ön-eğitim yaklaşımı sunmuş ve hiperparametrelerin, eğitim verisi miktarının ve eğitim reçetesinin model performansı üzerindeki etkisini açıkça göstermiştir [6]. DistilBERT ise bilgi damıtımı yaklaşımıyla BERT'in daha hafif ve daha hızlı bir versiyonunu sunmuş; bu nedenle sınırlı donanım koşullarında transformer tabanlı sınıflandırma deneyleri için pratik bir alternatif haline gelmiştir [7].

Fake news detection literatüründe BERT tabanlı modellerin güçlü performans verdiğini gösteren çeşitli çalışmalar bulunmaktadır. Kaliyar vd. [8], BERT tabanlı FakeBERT yaklaşımı ile geleneksel derin öğrenme modellerine kıyasla daha etkili sonuçlar elde edilebildiğini göstermiştir. Benzer şekilde, transformer tabanlı modelleri karşılaştıran çalışmalar, BERT, RoBERTa ve ALBERT gibi

mimarilerin fake news classification görevlerinde güçlü baseline modeller olarak kullanılabileceğini ortaya koymaktadır [9]. Bu bulgular, fake news detection probleminde yalnızca yüzeysel kelime örüntülerine değil, bağlamsal ve semantik temsillere dayanan modellerin daha uygun olduğunu göstermektedir.

Bununla birlikte, literatür fake news detection performansının yalnızca model mimarisiyle açıklanamayacağını da göstermektedir. Veri seti seçimi, feature representation, veri birleştirme yöntemleri ve değerlendirme protokolleri sonuçları doğrudan etkileyebilmektedir. FakeNewsNet ve NELA-GT gibi veri setleri, haber içeriği, kaynak bilgisi, sosyal bağlam ve doğruluk etiketleri gibi farklı bileşenleri bir araya getirerek fake news detection çalışmalarında önemli benchmark kaynakları haline gelmiştir [10], [11], [12]. Özellikle NELA-GT veri ailesi, kaynak düzeyinde etiketleme ve haber makalesi ölçeğinde büyük veri sunması nedeniyle, GPT-etiketli fake news sınıflandırması çalışmalarının veri altyapısında önemli bir rol oynamaktadır.

Raza, Paulen-Patterson ve Ding'in çalışması da bu transformer tabanlı fake news detection çizgisini devam ettirmektedir. Yazarlar, BERT-like encoder-only modeller ile autoregressive decoder-only LLM modellerini fake news classification görevi üzerinde karşılaştırmış; BERT-like modellerin sınıflandırma görevlerinde genel olarak daha güçlü performans gösterdiğini, buna karşılık LLM'lerin text perturbation koşullarında daha dayanıklı olabildiğini raporlamıştır [13]. Ayrıca çalışma, GPT-4 destekli ve insan denetimli etiketleme süreciyle oluşturulan verinin, source-level weak supervision etiketlerine kıyasla daha güvenilir sınıflandırma sonuçları üretebildiğini göstermektedir [13]. Bu durum, fake news detection alanında hem transformer mimarilerinin hem de veri etiketleme kalitesinin birlikte ele alınması gerektiğini ortaya koymaktadır.

Bu çalışma, söz konusu literatür doğrultusunda fake news detection problemini GPT-etiketli haber verisi üzerinde BERT-like modellerle ele almaktadır. DistilBERT, RoBERTa ve BERT-base gibi transformer tabanlı modellerin aynı veri bölünmesi üzerinde karşılaştırılması, literatürdeki encoder-only model çizgisini yeniden üretim ve geliştirme bağlamında incelemeyi mümkün kılmaktadır. Ayrıca bu çalışmada model performansı yalnızca accuracy üzerinden değil; precision, recall ve F1-score metrikleri üzerinden değerlendirilerek, veri setindeki class imbalance ve precision-recall tradeoff etkileri de dikkate alınmaktadır. Bu yönüyle çalışma, transformer tabanlı fake news detection literatürünü yalnızca model karşılaştırması açısından değil, yeniden üretilebilirlik ve metrik duyarlılığı açısından da genişletmektedir.

2.2 BERT-like Modeller ve Large Language Models Karşılaştırmaları

BERT-like modeller, metin sınıflandırma görevlerinde encoder-only mimarileri sayesinde güçlü bağlamsal temsil üretme kapasitesine sahiptir. Bu modeller, fine-tuning yoluyla belirli bir sınıflandırma görevine doğrudan uyarlanabilir ve classification head üzerinden optimize edilebilir. Bu nedenle BERT, RoBERTa ve DistilBERT gibi modeller, fake news detection gibi supervised text classification problemlerinde sık kullanılan güçlü baseline modeller haline gelmiştir [5], [6], [7].

Buna karşılık Large Language Models (LLMs), özellikle GPT-3, GPT-4, Llama ve Mistral gibi decoder-only veya instruction-tuned mimariler üzerinden zero-shot, few-shot ve instruction-following yaklaşımlarıyla değerlendirilmektedir [14], [15], [16], [17]. LLM'ler geniş ölçekli ön-eğitim verisi ve üretici dil modelleme kapasiteleri sayesinde bağlamsal akıl yürütme, açıklama üretme ve farklı metin varyasyonlarına uyum sağlama açısından güçlüdür. Ancak bu modellerin saf sınıflandırma görevlerinde her zaman fine-tuned encoder modelleri geçmesi beklenmemelidir. Çünkü encoder-only

modeller, sınıflandırma hedefi için doğrudan optimize edilirken, LLM tabanlı yaklaşımlar çoğu zaman prompting, few-shot örnekleme veya daha pahalı fine-tuning süreçlerine bağlıdır.

Raza vd. [13], bu ayrımı fake news detection bağlamında doğrudan inceleyen temel çalışmalardan biridir. Çalışmada BERTBase, RoBERTaBase ve DistilBERT gibi BERT-like modeller; Llama2-7B ve Mistral-7B-Instruct gibi autoregressive LLM'lerle karşılaştırılmıştır. Yazarlar, GPT-etiketli fake news verisi üzerinde BERT-like modellerin sınıflandırma performansı bakımından LLM'lere göre daha başarılı olduğunu, buna karşılık LLM'lerin text perturbation koşullarında daha dayanıklı davranabildiğini raporlamıştır [13]. Bu bulgu, model seçiminin yalnızca büyüklük veya güncellik üzerinden değil, görev tipi ve değerlendirme koşulları üzerinden yapılması gerektiğini göstermektedir.

LLM'lerin misinformation ve fake news detection görevlerindeki rolü son yıllarda artmıştır. Bang vd. [18], ChatGPT'nin farklı NLP görevlerindeki zero-shot performansını değerlendirerek LLM'lerin bazı görevlerde güçlü sonuçlar verebildiğini, ancak performansın görev türüne ve veri yapısına göre değiştiğini göstermiştir. Hu vd. [19] ise LLM'lerin fake news detection görevinde tek başına sınıflandırıcı olarak her zaman en iyi sonuçları üretmediğini, ancak yardımcı/advisor rolünde kullanıldığında karar verme sürecine katkı sağlayabildiğini göstermektedir. Bu sonuçlar, fake news detection alanında LLM'lerin doğrudan classifier olarak değil, annotation, explanation, verification veya decision support aşamalarında daha etkili kullanılabileceğini düşündürmektedir.

Bu bağlamda, mevcut çalışma BERT-like modelleri merkeze almaktadır. Bunun nedeni, çalışmanın temel amacının LLM tabanlı prompting stratejilerini test etmek değil, GPT-etiketli veri üzerinde BERT-like classification pipeline'ın yeniden üretilebilirliğini ve geliştirme potansiyelini analiz etmektir. Bu nedenle DistilBERT, RoBERTa ve BERT-base mimarileri karşılaştırılmış; model performansı accuracy, precision, recall ve F1-score üzerinden değerlendirilmiştir. Bu yaklaşım, Raza vd. [13] tarafından raporlanan BERT-like modellerin güçlü supervised classification davranışını yerel deney ortamında yeniden değerlendirmeyi mümkün kılmaktadır.

2.3 AI-assisted Labeling, GPT Labels ve Label Quality

Fake news detection çalışmalarında önemli problemlerden biri güvenilir etiketli veri elde etmektir. Haber içeriklerinin gerçek veya sahte olarak etiketlenmesi çoğu zaman uzman doğrulaması, fact-checking süreçleri, kaynak güvenilirliği analizi veya insan anotasyonu gerektirir. Bu süreçler hem zaman alıcı hem de maliyetlidir. Bu nedenle literatürde distant supervision, weak supervision ve son yıllarda LLM-assisted annotation yaklaşımları daha fazla kullanılmaya başlanmıştır [20], [21].

Distant supervision yaklaşımı, doğrudan tekil örnekleri elle etiketlemek yerine, dış kaynaklardan veya bilgi tabanlarından gelen zayıf sinyallerle etiket üretmeyi amaçlar [20]. Fake news detection alanında bu yaklaşım çoğu zaman haber kaynağının genel güvenilirliği üzerinden etiket üretme biçiminde karşımıza çıkar. Örneğin NELA-GT gibi veri setlerinde haber kaynaklarının güvenilirlik düzeyi, makale düzeyindeki sınıflandırma çalışmaları için zayıf etiket sinyali olarak kullanılabilir [11], [12]. Ancak source-level labeling yaklaşımı, tekil bir haberin içeriğini doğrudan doğrulamadığı için label noise üretme riski taşır. Güvenilir bir kaynaktan çıkan yanlış bir haber veya güvenilirliği düşük bir kaynaktan çıkan doğru bir haber, kaynak düzeyinde yapılan etiketlemede hatalı sınıflandırılabilir.

Bu sınırlılıklar, LLM destekli etiketleme yaklaşımlarını önemli hale getirmiştir. Gilardi vd. [21], ChatGPT'nin bazı metin anotasyonu görevlerinde crowd-worker etiketlerine kıyasla yüksek doğruluk sağlayabildiğini ve anotasyon maliyetini azaltabileceğini göstermiştir. Benzer şekilde, Wang vd. [22], GPT-3 ile üretilen etiketlerin bazı NLP görevlerinde downstream classifier eğitimi için

kullanılabileceğini ortaya koymuştur. Bu çalışmalar, LLM'lerin insan anotasyonunun yerine tamamen geçmesi gerektiğini değil, kontrollü ve doğrulamalı etiket üretim süreçlerinde yardımcı araç olarak kullanılabileceğini göstermektedir.

Bununla birlikte, LLM tabanlı etiketleme süreçleri de hatasız değildir. LLM'ler hallucination, sistematik bias, prompt sensitivity ve görevden göreve değişen annotation quality problemleri gösterebilir [23], [24]. Ji vd. [23], LLM'lerde hallucination probleminin üretici modellerin güvenilirliğini sınırlayan önemli bir unsur olduğunu vurgulamaktadır. Motoki vd. [24] ise ChatGPT çıktılarına politik yönelim ve sistematik bias bulunabileceğini göstermektedir. Bu nedenle GPT veya başka bir LLM tarafından oluşturulan etiketlerin doğrudan kesin doğruluk kabul edilmesi metodolojik olarak risklidir.

Raza vd. [13], bu sorunu azaltmak için GPT-4 destekli etiketleme sürecini insan doğrulamasıyla birleştirmiştir. Yazarlar, GPT tabanlı annotation sürecinden sonra insan reviewer kontrolü uygulayarak etiket kalitesini artırmayı hedeflemiştir. Bu yöntem, yalnızca source-level weak supervision'a dayalı etiketlerden farklı olarak article-level labeling yaklaşımı sunmaktadır. Bu çalışma kapsamında kullanılan gpt label alanı da bu bağlamda önemlidir; çünkü model, geleneksel kaynak güvenilirliği etiketleri yerine GPT destekli ve insan denetimiyle ilişkilendirilen etiketleri hedef değişken olarak öğrenmektedir.

Mevcut çalışma, GPT-labeled fake news verisi üzerinde BERT-like modelleri değerlendirdiği için label quality meselesi doğrudan model performansı ile ilişkilidir. Eğer GPT etiketlerinde noise, belirsizlik veya sınıf dağılımı problemi varsa, bu durum modelin recall, precision ve F1-score değerlerini etkileyebilir. Bu nedenle çalışma, yalnızca model mimarilerini karşılaştırmakla kalmayıp, GPT-labeled veri üzerinde ortaya çıkan class imbalance ve precision-recall tradeoff problemlerini de analiz etmektedir.

2.4 Class Imbalance, Weighted Loss ve Threshold Tuning

Class imbalance, sınıflandırma problemlerinde bir veya daha fazla sınıfın diğer sınıflara göre belirgin biçimde az temsil edilmesi durumudur. Bu problem özellikle binary classification görevlerinde modelin çoğunluk sınıfına yönelmesine ve minority class örneklerini kaçırmaya neden olabilir. Fake news detection gibi görevlerde bu durum kritiktir; çünkü model yüksek accuracy üretse bile minority class için düşük recall ve düşük F1-score gösterebilir. Bu nedenle class imbalance bulunan veri setlerinde accuracy tek başına yeterli değildir; precision, recall ve F1-score birlikte değerlendirilmelidir [25], [26].

Class imbalance problemini ele almak için literatürde sampling tabanlı, cost-sensitive learning tabanlı ve threshold tabanlı birçok yaklaşım önerilmiştir. SMOTE, minority class örnekleri için sentetik örnekler üreterek sınıf dağılımını dengelemeyi amaçlayan temel yöntemlerden biridir [27]. Deep learning bağlamında ise focal loss, modelin kolay sınıflandırılan örnekler yerine zor örnekler daha fazla odaklanmasını sağlayarak dengesiz veri setlerinde performansı artırmayı hedefler [28]. Bunun yanında class-balanced loss gibi yeniden ağırlıklandırma yöntemleri, sınıf frekanslarını dikkate alarak loss fonksiyonunu düzenlemektedir [29].

NLP ve transformer tabanlı sınıflandırma görevlerinde de class imbalance önemli bir problemdir. Madabushi vd. [30], cost-sensitive BERT fine-tuning yaklaşımının dengesiz sınıflandırma görevlerinde minority class performansını artırabileceğini göstermiştir. Henning vd. [31] ise NLP görevlerinde class imbalance problemini ele alan yöntemleri inceleyerek sampling, reweighting,

augmentation ve threshold adjustment gibi stratejilerin görev bağlamına göre farklı etkiler gösterebileceğini vurgulamıştır. Bu çalışmalar, BERT-like modellerde class imbalance probleminin yalnızca daha büyük model kullanarak çözülemeyeceğini; eğitim stratejisi ve değerlendirme metriklerinin de dikkatli tasarlanması gerektiğini göstermektedir.

Weighted loss, class imbalance durumunda yaygın kullanılan cost-sensitive learning yöntemlerinden biridir. Bu yaklaşımda minority class örnekleri loss fonksiyonunda daha yüksek ağırlıkla değerlendirilir. Böylece modelin azınlık sınıfı görmezden gelme eğilimi azaltılmaya çalışılır. Ancak bu yöntemin doğal bir riski vardır: minority class recall değeri artarken, model daha fazla false positive üretebilir ve precision değeri düşebilir. Bu nedenle weighted loss çoğu zaman precision-recall tradeoff yaratır.

Threshold tuning ise modelin tahmin olasılıklarını sınıfa dönüştürürken kullandığı karar eşiğinin ayarlanmasıdır. Binary classification görevlerinde varsayılan threshold çoğunlukla 0.5 olarak kabul edilir. Ancak class imbalance bulunan veri setlerinde 0.5 threshold değeri optimum F1-score veya optimum recall-precision dengesi sağlamayabilir. Esposito vd. [32], dengesiz binary classification problemlerinde decision threshold optimizasyonunun performansı etkileyebileceğini göstermiştir. Bu nedenle threshold adjustment yaklaşımları, modelin default karar sınırını değiştirerek minority class performansını ve precision-recall dengesini analiz etmek için kullanılmaktadır.

Bu çalışmada class imbalance problemi doğrudan deneysel bulgularla ilişkili olduğu için weighted loss, mild weighted loss ve threshold tuning yöntemleri test edilmiştir. İlk weighted loss denemesi recall değerini belirgin biçimde artırmış, ancak precision değerini düşürmüştür. Bu nedenle daha yumuşak bir ağırlıklandırma stratejisi olarak mild weighted loss uygulanmıştır. Ayrıca DistilBERT baseline modelinin validation set çıktıları üzerinde threshold search yapılmış ve en iyi validation F1-score değerini veren threshold test setinde değerlendirilmiştir. Bu deneyler, literatürde önerilen class imbalance handling yaklaşımlarını GPT-labeled fake news classification bağlamında test etmeyi amaçlamaktadır.

Bu bağlamda çalışma, yalnızca model karşılaştırması yapan bir yeniden üretim çalışması değil, aynı zamanda class imbalance kaynaklı precision-recall tradeoff'u analiz eden kontrollü bir deneysel çalışma olarak konumlanmaktadır. Sonuçların test F1-score bakımından baseline modelin üzerine çıkmaması, bu yöntemlerin değersiz olduğu anlamına gelmemektedir. Aksine, farklı yöntemlerin farklı metriklerde nasıl davranış ürettiğini göstermesi açısından önemlidir. Bu yönüyle çalışma, fake news detection literatüründe model performansının yalnızca tek bir skorla değil, metrikler arası denge ve veri seti özellikleriyle birlikte değerlendirilmesi gerektiğini desteklemektedir.

3. Material and Methods (Materyal ve Yöntem)

Bu çalışmada, GPT-etiketli fake news verisi üzerinde BERT-like transformer modelleri kullanılarak bir binary text classification pipeline oluşturulmuştur. Deneysel süreç iki ana bölümden oluşmaktadır: ilk olarak seçilen çalışmadaki BERT-like model yaklaşımı yeniden uygulanmış, ardından elde edilen bulgular doğrultusunda model performansını geliştirmeye yönelik kontrollü deneyler gerçekleştirilmiştir.

3.1 Veri Seti

Çalışmada, Raza, Paulen-Patterson ve Ding tarafından paylaşılan GitHub reposu üzerinden yönlendirilen newsmediabias/NELA-GT_GPT-Labels_Dataset veri seti kullanılmıştır. Orijinal

çalışmada, GPT-4 desteğiyle etiketlenmiş ve insan uzmanlar tarafından doğrulanmış 10.000 haber örneğinden oluşan bir veri seti kullanıldığı belirtilmektedir. Bu çalışmada ise yazarların reposu üzerinden erişilen Hugging Face veri setinin mevcut sürümü kullanılmıştır. Erişilen sürüm toplam 5.414 örnek içermektedir. Bu nedenle bu çalışma, orijinal deneysel kurulumun birebir kopyası olmaktan ziyade, yazarların paylaştığı veri kaynağı üzerinden gerçekleştirilen bir reproduction ve geliştirme çalışması olarak değerlendirilmelidir.

Veri seti haber metinlerinden oluşmakta ve her örnek için aşağıdaki alanları içermektedir:

- **title:** haber başlığı
- **content:** haber içeriği
- **nla label:** kaynak güvenilirliği veya geleneksel etiketleme yaklaşımıyla ilişkilendirilen etiket
- **gpt label:** GPT destekli etiketleme süreciyle oluşturulan etiket

Bu çalışmada hedef değişken olarak gpt label kullanılmıştır. Hedef değişken dağılımı aşağıdaki gibidir:

Label	Örnek Sayısı
0	4429
1	985

Bu dağılım, veri setinde belirgin bir class imbalance problemi olduğunu göstermektedir. Bu çalışmada pozitif sınıf olarak gpt label = 1 kabul edilmiştir. Sınıf dağılımı incelendiğinde gpt label = 1 sınıfının daha az sayıda örnek içerdiği görülmüş ve bu sınıf minority class olarak değerlendirilmiştir. Bu nedenle deneysel değerlendirmede yalnızca accuracy değil, precision, recall ve F1-score metrikleri birlikte kullanılmıştır.

3.2 Veri Ön İşleme

Veri seti üzerinde öncelikle eksik değer kontrolü yapılmış ve kullanılan sürümde title, content, nla label ve gpt label alanlarında eksik değer bulunmadığı gözlemlenmiştir. Model girdisi oluşturulurken haber başlığı ve haber içeriği birlikte kullanılmıştır. Bu amaçla her örnek için bir metin yapısı oluşturulmuştur: *title + content*

Transformer modellerinin giriş formatına uygun olması için metinler ilgili modelin tokenizer'ı ile dönüştürülmüştür. Tokenization sürecinde:

- maksimum giriş uzunluğu **512 token** olarak belirlenmiştir,
- uzun metinler **truncation** ile kesilmiştir,
- kısa metinler **padding** ile aynı uzunluğa getirilmiştir,
- model girdileri **input_ids**, **attention_mask** ve gerekli modeller için **token_type_ids** alanlarıyla hazırlanmıştır.

Veri seti, deneylerin yeniden üretilebilirliğini sağlamak amacıyla **stratified split** kullanılarak aşağıdaki şekilde bölünmüştür:

Bölüm	Oran	Örnek Sayısı
-------	------	--------------

Train	%80	4331
Validation	%10	541
Test	%10	542

Stratified split kullanılarak her bölümde sınıf dağılımının mümkün olduğunca korunması amaçlanmıştır.

Veri bölme aşamasında yeniden üretilebilirliği artırmak amacıyla sabit random seed değeri (42) kullanılmıştır. Bununla birlikte, model eğitimleri tek bir run üzerinden raporlanmıştır; farklı seed değerleriyle tekrarlı deneyler yapılmamış olması bu çalışmanın sınırlılıklarından biridir.

3.3 Model Mimarileri

Çalışmada üç temel BERT-like model yaklaşımı değerlendirilmiştir.

3.3.1 DistilBERT

DistilBERT, BERT mimarisinin daha küçük ve daha hızlı bir versiyonudur. Bu çalışmada distilbert-base-uncased modeli baseline model olarak kullanılmıştır. DistilBERT, daha düşük hesaplama maliyetine sahip olması nedeniyle yerel donanım koşullarında yeniden üretim ve geliştirme deneyleri için uygun bir başlangıç noktası sağlamıştır.

3.3.2 RoBERTa

RoBERTa, BERT mimarisinin eğitim stratejileri açısından geliştirilmiş bir versiyonudur. Bu çalışmada roberta-base modeli kullanılmıştır. RoBERTa'nın daha güçlü temsil kapasitesine sahip olması beklenmekle birlikte, deney sonuçları model performansının yalnızca mimari güce bağlı olmadığını göstermiştir.

3.3.3 BERT-base

Geliştirme deneyleri kapsamında bert-base-uncased modeli de test edilmiştir. Bu deneyin amacı, DistilBERT'e kıyasla daha büyük ve tam BERT encoder mimarisinin performansa etkisini analiz etmektir. BERT-base deneyi, farklı BERT-like mimarilerin aynı veri bölünmesi üzerindeki davranışını karşılaştırmak için kullanılmıştır.

3.4 Baseline Yeniden Üretim Deneyleri

İlk deney setinde aşağıdaki modeller uygulanmıştır:

- **DistilBERT baseline**
- **RoBERTa baseline**
- **DistilBERT with weighted loss**

Bu deneylerde amaç, seçilen çalışmadaki BERT-like classification yaklaşımını erişilen veri seti sürümü ve yerel donanım koşulları altında yeniden uygulamak ve elde edilen sonuçları karşılaştırmaktır.

Baseline deneylerinde genel eğitim yapılandırması aşağıdaki gibidir:

Parametre	Değer
Epoch	3
Learning rate	2e-5
Weight decay	0.01
Optimizer	AdamW
Max sequence length	512
Model selection	Validation F1-score
Evaluation strategy	Epoch bazlı

Batch size değeri modelin bellek ihtiyacına göre belirlenmiştir. DistilBERT deneylerinde batch size 8, RoBERTa ve BERT-base gibi daha yüksek bellek gerektiren modellerde ise batch size 4 kullanılmıştır.

3.5 Geliştirme Deneyleri

Baseline sonuçları incelendiğinde, model performansında özellikle minority class recall değerinin sınırlı kaldığı görülmüştür. Bu durumun temel nedenlerinden biri veri setindeki class imbalance olarak değerlendirilmiştir. Bu nedenle geliştirme deneyleri, class imbalance ve precision-recall tradeoff problemlerine odaklanacak şekilde tasarlanmıştır.

Bu kapsamda aşağıdaki deneyler gerçekleştirilmiştir:

Threshold Tuning

Varsayılan classification threshold değeri genellikle 0.5 olarak alınmaktadır. Ancak class imbalance bulunan veri setlerinde bu eşik değeri en iyi F1-score değerini vermeyebilir. Bu nedenle DistilBERT baseline modelinin validation set tahminleri üzerinde 0.10-0.90 aralığında threshold taraması yapılmış ve validation F1-score değerini en yüksek yapan threshold seçilmiştir. Seçilen threshold daha sonra test set üzerinde uygulanmıştır.

Mild Weighted Loss

İlk weighted loss deneyinde sınıf frekanslarına ters orantılı ağırlıklar kullanılmıştır. Bu yaklaşım recall değerini artırmış, ancak precision değerinde ciddi düşüşe neden olmuştur. Bu nedenle geliştirme deneylerinde daha yumuşak bir ağırlıklandırma stratejisi uygulanmıştır. Sınıf ağırlıkları, ters frekans ağırlıklarının karekökü alınarak hesaplanmıştır:

$$mild\ weight = \sqrt{inverse\ frequency\ weight}$$

Bu yaklaşımın amacı, minority class'a daha fazla önem verirken aggressive weighted loss yaklaşımında görülen precision düşüşünü azaltmaktır.

Epoch Artırma

Modelin daha uzun eğitimle daha iyi öğrenip öğrenmediğini test etmek amacıyla DistilBERT modeli 3 epoch yerine 5 epoch eğitilmiştir. Bu deney, daha uzun eğitimin performansa etkisini ve olası overfitting davranışını analiz etmek için kullanılmıştır.

Learning Rate Düşürme

Daha kontrollü fine-tuning sağlamak amacıyla learning rate değeri $2e-5$ değerinden $1e-5$ değerine düşürülmüştür. Bu deneyin amacı, daha düşük learning rate ile modelin validation ve test performansında daha dengeli bir davranış gösterip göstermediğini incelemektir.

BERT-base Architecture Comparison

Son olarak, DistilBERT baseline'a kıyasla daha büyük bir encoder mimarisi olan BERT-base modeli test edilmiştir. Bu deney, performans farkının yalnızca eğitim parametrelerinden değil, model mimarisinden de etkilenip etkilenmediğini analiz etmek amacıyla gerçekleştirilmiştir.

3.6 Değerlendirme Metrikleri

Model performansı aşağıdaki metrikler kullanılarak değerlendirilmiştir:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-score**

Class imbalance bulunan veri setlerinde accuracy tek başına yeterli bir performans göstergesi değildir. Bu nedenle özellikle precision, recall ve F1-score değerleri birlikte yorumlanmıştır. Bu çalışmada ana karşılaştırma metriği olarak F1-score kullanılmıştır. Bunun nedeni, F1-score'un precision ve recall değerlerini birlikte dikkate alması ve dengesiz sınıf dağılımlarında daha anlamlı bir genel performans göstergesi sunmasıdır.

3.7 Deney Ortamı

Deneyler yerel bir bilgisayar üzerinde gerçekleştirilmiştir. Kullanılan temel donanım ve yazılım ortamı aşağıdaki gibidir:

Bileşen	Bilgi
GPU	NVIDIA GeForce RTX 3070 Ti Laptop GPU
GPU Belleği	8 GB
Python	3.12
Framework	PyTorch
Kütüphaneler	Hugging Face Transformers, Datasets, scikit-learn, pandas, matplotlib

Yerel donanımın sınırlı GPU belleği nedeniyle bazı modellerde batch size daha düşük tutulmuştur. Bu durum, orijinal çalışmadaki deney ortamı ile bu çalışmadaki sonuçlar arasındaki farkları açıklayabilecek faktörlerden biri olarak değerlendirilmiştir.

Kod ve deney çıktıları yazar tarafından yerel olarak saklanmış; gerektiğinde paylaşılmak üzere GitHub reposu olarak düzenlenmiştir.

4. Experimental Results (Deneysel Sonuçlar)

Bu bölümde, yeniden üretim ve geliştirme deneylerinden elde edilen sonuçlar sunulmaktadır. Tüm modeller aynı veri bölünmesi üzerinde değerlendirilmiş ve performans karşılaştırması accuracy, precision, recall ve F1-score metrikleri üzerinden yapılmıştır. Ana karşılaştırma metriği olarak F1-score kullanılmıştır; çünkü veri setinde belirgin bir class imbalance bulunduğundan accuracy tek başına yeterli bir performans göstergesi değildir.

4.1 Yeniden Üretim Deneyleri

İlk deney setinde DistilBERT, RoBERTa ve weighted loss uygulanmış DistilBERT modelleri değerlendirilmiştir. Bu deneylerin amacı, seçilen çalışmadaki BERT-like classification yaklaşımını erişilen veri seti sürümü ve yerel donanım koşullarında yeniden uygulamaktır.

Tablo 1. Yeniden üretim deneylerinin validation ve test sonuçları

Model	Val Accuracy	Val Precision	Val Recall	Val F1	Test Accuracy	Test Precision	Test Recall	Test F1
DistilBERT	0.8651	0.7119	0.4286	0.5350	0.8708	0.7302	0.4646	0.5679
RoBERTa	0.8484	0.7222	0.2653	0.3881	0.8598	0.7949	0.3131	0.4493
DistilBERT Weighted	0.8429	0.5596	0.6224	0.5894	0.8173	0.5000	0.6465	0.5639

Tablo 1 incelendiğinde, test F1-score bakımından en yüksek sonucun 0.5679 ile DistilBERT baseline modelinde elde edildiği görülmektedir. RoBERTa modeli test precision açısından yüksek bir değer üretmiş olsa da, test recall değerinin 0.3131 seviyesinde kalması nedeniyle genel F1 performansında geride kalmıştır. Bu durum, RoBERTa modelinin daha seçici tahminler ürettiğini, ancak minority class örneklerini yeterince yakalayamadığını göstermektedir.

Weighted loss uygulanmış DistilBERT modelinde ise test recall değeri 0.6465 seviyesine yükselmiştir. Bu, minority class örneklerini yakalama açısından önemli bir artıştır. Ancak aynı modelde test precision değeri 0.5000 seviyesine düşmüş ve test accuracy da azalmıştır. Dolayısıyla weighted loss yaklaşımı recall değerini artırmış, ancak precision ve accuracy üzerinde olumsuz bir etki yaratmıştır. Bu sonuç, veri setinde belirgin bir precision-recall tradeoff olduğunu göstermektedir.

4.2 Geliştirme Deneyleri

Yeniden üretim deneylerinden elde edilen sonuçlar, temel problemin yalnızca model mimarisi olmadığını; veri setindeki class imbalance ve buna bağlı precision-recall tradeoff olduğunu göstermiştir. Bu nedenle geliştirme deneyleri, bu soruna yönelik kontrollü müdahaleler olarak tasarlanmıştır.

Bu kapsamda aşağıdaki deneyler gerçekleştirilmiştir:

- Threshold tuning

- Mild weighted loss
- Epoch artırma
- Learning rate düşürme
- BERT-base architecture comparison

Tablo 2. Geliştirme deneylerinin test sonuçları

Deney	Model	Değişiklik	Test Accuracy	Test Precision	Test Recall	Test F1
Baseline	DistilBERT	Baseline	0.8708	0.7302	0.4646	0.5679
Threshold Tuning	DistilBERT	Threshold = 0.48	0.8690	0.7188	0.4646	0.5644
Mild Weighted Loss	DistilBERT	Sqrt class weights	0.8376	0.5534	0.5758	0.5644
5 Epoch	DistilBERT	Epoch 3 → 5	0.8598	0.6575	0.4848	0.5581
Lower Learning Rate	DistilBERT	LR 2e-5 → 1e-5	0.8506	0.6071	0.5152	0.5574
BERT-base	BERT-base	Farklı BERT-like mimari	0.8727	0.7679	0.4343	0.5548

Tablo 2'ye göre geliştirme deneylerinin hiçbirisi test F1-score bakımından DistilBERT baseline sonucunu aşamamıştır. Bununla birlikte, farklı yöntemler farklı metriklerde iyileşme sağlamıştır. BERT-base modeli test accuracy ve precision açısından en yüksek değerleri üretmiştir. Test accuracy değeri 0.8727, test precision değeri ise 0.7679 olarak elde edilmiştir. Ancak BERT-base modelinin test recall değeri 0.4343 seviyesinde kalmış ve bu nedenle F1-score bakımından baseline modelin gerisinde kalmıştır.

Mild weighted loss yaklaşımı test recall değerini 0.5758 seviyesine yükseltmiştir. Bu değer, DistilBERT baseline modelinin test recall değeri olan 0.4646 değerinden yüksektir. Ancak precision değerindeki düşüş nedeniyle F1-score artmamıştır. Benzer şekilde, learning rate değerinin 2e-5 seviyesinden 1e-5 seviyesine düşürülmesi recall değerini 0.5152 seviyesine çıkarmış, fakat precision düşüşü nedeniyle genel F1-score iyileşmemiştir.

Epoch sayısının 3'ten 5'e çıkarılması test recall değerinde sınırlı bir artış sağlamış, ancak test precision ve F1-score değerlerinde düşüşe neden olmuştur. Bu nedenle daha uzun eğitim, bu deneysel kurulumda genel performans açısından etkili bir iyileştirme sağlamamıştır.

4.3 Threshold Tuning Sonuçları

Threshold tuning deneyinde, DistilBERT baseline modelinin validation set tahminleri üzerinde 0.10 ile 0.90 aralığında threshold taraması yapılmıştır. Validation F1-score değerini en yüksek yapan threshold değeri 0.48 olarak belirlenmiştir.

Bu threshold test set üzerinde uygulandığında aşağıdaki sonuçlar elde edilmiştir:

Threshold	Test Accuracy	Test Precision	Test Recall	Test F1
0.48	0.8690	0.7188	0.4646	0.5644

Threshold tuning validation set üzerinde küçük bir iyileşme sağlamış olsa da, test setinde DistilBERT baseline F1-score değerini aşamamıştır. Bu durum, validation set üzerinde seçilen threshold değerinin test set genellemesine sınırlı katkı sağladığını göstermektedir.

4.4 Genel Sonuç Özeti

Deneyler genel olarak değerlendirildiğinde üç temel bulgu öne çıkmaktadır:


1. **DistilBERT baseline**, test F1-score bakımından en güçlü genel model olarak kalmıştır.
2. **Weighted loss tabanlı yaklaşımlar**, minority class recall değerini artırmış ancak precision düşüşü nedeniyle F1-score'u iyileştirememiştir.
3. **BERT-base**, accuracy ve precision açısından en yüksek değerleri üretmiş ancak recall düşüşü nedeniyle genel F1-score bakımından baseline modelin gerisinde kalmıştır.

Bu sonuçlar, GPT-labeled fake news classification probleminde performansın yalnızca model mimarisine bağlı olmadığını göstermektedir. Özellikle class imbalance, threshold selection ve training configuration gibi faktörler modelin hangi metrikte güçlü veya zayıf sonuç vereceğini doğrudan etkilemektedir.

4.5 Grafıksel Değerlendirme


Elde edilen sonuçların daha açık görülebilmesi için test metrikleri grafıksel olarak da karşılaştırılmıştır.

Şekil 1, test F1-score değerlerini karşılaştırmaktadır. Bu grafik, DistilBERT baseline modelinin genel performans açısından en güçlü sonucu verdiğini göstermektedir.




Şekil 1. Test F1-score karşılaştırması

Şekil 2, test precision ve recall değerlerini birlikte göstermektedir. Weighted loss tabanlı yaklaşımların recall değerini artırdığı, ancak buna karşılık precision değerinde düşüşe yol açtığı görülmektedir. Bu sonuç, veri setinde belirgin bir precision-recall tradeoff olduğunu desteklemektedir.



Şekil 2. Test precision ve recall karşılaştırması

Şekil 3, tüm test metriklerini birlikte sunmaktadır. Bu grafik, farklı yöntemlerin farklı metriklerde avantaj sağladığını; ancak test F1-score bakımından baseline DistilBERT modelinin aşılamadığını göstermektedir.



Şekil 3. Tüm test metriklerinin karşılaştırması

Bu grafikler, deneylerde gözlenen temel eğilimi desteklemektedir: bazı yöntemler belirli metriklerde iyileşme sağlasa da, genel performans ölçütü olarak kullanılan test F1-score açısından DistilBERT baseline modeli en güçlü sonuç olarak kalmıştır.

5. Discussion (Tartışma)

Bu çalışmada, GPT-etiketlenmiş fake news classification problemi için BERT-like modeller temelinde yeniden üretim ve geliştirme deneyleri gerçekleştirilmiştir. Deney sonuçları, uygulanan geliştirme stratejilerinin bazı metriklerde iyileşme sağladığını, ancak test F1-score bakımından DistilBERT baseline modelinin aşılamadığını göstermiştir. Bu durum, model performansının yalnızca model mimarisi veya tekil hiperparametre değişiklikleriyle açıklanamayacağını; veri seti yapısı, sınıf

dağılımı, karar eşiği, eğitim konfigürasyonu ve deney ortamı gibi faktörlerin birlikte değerlendirilmesi gerektiğini ortaya koymaktadır.

5.1 Baseline Modelin Genel Performansı

Yeniden üretim deneylerinde en yüksek test F1-score değeri 0.5679 ile DistilBERT baseline modelinde elde edilmiştir. Bu sonuç, DistilBERT'in daha küçük ve daha hafif bir model olmasına rağmen bu veri seti üzerinde dengeli bir performans sunduğunu göstermektedir. RoBERTa ve BERT-base gibi daha büyük veya daha güçlü temsil kapasitesine sahip modellerin F1-score bakımından DistilBERT baseline sonucunu geçememesi, model büyüklüğünün tek başına daha iyi performans anlamına gelmediğini göstermektedir.

BERT-base modeli test accuracy ve precision açısından en yüksek değerleri üretmiştir. Ancak test recall değerinin düşük kalması nedeniyle F1-score bakımından baseline modelin gerisinde kalmıştır. Bu durum, BERT-base modelinin daha seçici tahminler ürettiğini, yani pozitif sınıf tahminlerinde daha dikkatli davrandığını; ancak bu seçiciliğin minority class örneklerinin bir kısmını kaçırmasına neden olduğunu göstermektedir.

5.2 Class Imbalance ve Precision-Recall Tradeoff Etkisi

Veri setinde gpt label dağılımı belirgin biçimde dengesizdir. Class 0 örneklerinin sayısı class 1 örneklerinden oldukça fazladır. Bu durum, modellerin çoğunluk sınıfına daha fazla eğilim göstermesine ve minority class örneklerinde düşük recall üretmesine neden olabilmektedir.

Weighted loss deneyleri bu durumu açık biçimde göstermiştir. Aggressive weighted loss yaklaşımı test recall değerini 0.6465 seviyesine çıkarmış, ancak test precision değerini 0.5000 seviyesine düşürmüştür. Mild weighted loss yaklaşımı ise recall değerini 0.5758 seviyesine yükseltmiş, fakat yine precision düşüşü nedeniyle F1-score bakımından baseline modelin gerisinde kalmıştır.

Bu bulgu, veri setinde güçlü bir precision-recall tradeoff olduğunu göstermektedir. Model minority class örneklerini daha fazla yakalamaya zorlandığında recall artmakta, ancak daha fazla false positive üretildiği için precision düşmektedir. Dolayısıyla class imbalance problemini yalnızca sınıf ağırlıklarını artırarak çözmek yeterli olmamıştır.

5.3 Threshold Tuning Deneyinin Değerlendirilmesi

Threshold tuning deneyinde, validation set üzerinde en iyi F1-score değerini veren threshold 0.48 olarak belirlenmiştir. Bu değer, varsayılan 0.5 threshold değerine oldukça yakındır. Test set üzerinde uygulandığında ise threshold tuning, DistilBERT baseline sonucunu aşamamıştır.

Bu sonuç iki şekilde yorumlanabilir. Birincisi, modelin ürettiği olasılık dağılımlarında karar sınırı zaten 0.5 değerine yakın bir noktada oluşmuş olabilir. İkincisi, validation set üzerinde seçilen threshold değeri test setine yeterince genellenmemiş olabilir. Bu nedenle threshold tuning, teorik olarak class imbalance problemlerinde anlamlı bir yöntem olsa da, bu veri seti ve model çıktıları üzerinde sınırlı etki göstermiştir.

5.4 Epoch ve Learning Rate Değişikliklerinin Etkisi

Epoch sayısının 3'ten 5'e çıkarılması, test recall değerinde sınırlı bir artış sağlamıştır. Ancak test precision ve F1-score değerlerinde düşüş gözlemlenmiştir. Bu nedenle yalnızca epoch sayısını artırmak, bu deneysel kurulumda etkili bir iyileştirme stratejisi olmamıştır. Bu sonuç, daha uzun

eğitimin model performansını otomatik olarak artırmadığını ve eğitim süresinin veri seti yapısı ile sınıf dağılımı dikkate alınarak değerlendirilmesi gerektiğini göstermektedir.

Learning rate değerinin $2e-5$ seviyesinden $1e-5$ seviyesine düşürülmesi de benzer bir sonuç üretmiştir. Daha düşük learning rate, modelin minority class örneklerini biraz daha fazla yakalamasına katkı sağlamış ve recall değerini artırmıştır. Ancak precision düşüşü nedeniyle genel F1-score iyileşmemiştir. Bu sonuç, daha kontrollü fine-tuning yaklaşımının bazı metriklerde fayda sağlayabileceğini, fakat tek başına genel performansı artırmak için yeterli olmadığını göstermektedir.

5.5 Orijinal Çalışmadaki Sonuçlara Neden Ulaşılamadı?

Bu çalışmada elde edilen sonuçlar, orijinal çalışmada raporlanan performans seviyelerine ulaşamamıştır. Bunun birkaç olası nedeni bulunmaktadır.

İlk olarak, kullanılan veri seti sürümü orijinal çalışmadaki veri setiyle birebir aynı değildir. Orijinal çalışmada GPT-4 desteğiyle etiketlenmiş ve insan doğrulamasından geçirilmiş 10.000 haber örneği üzerinden deneyler yürütülmüştür. Bu çalışmada ise yazarların reposu üzerinden yönlendirilen Hugging Face veri setinin erişilebilen 5.414 örnekle sürümü kullanılmıştır. Dolayısıyla örnek sayısı, veri dağılımı, split yapısı ve olası preprocessing farkları, model performansının orijinal çalışmadaki sonuçlardan farklılaşmasına yol açmış olabilir.

İkinci olarak, orijinal çalışmadaki tüm preprocessing ayrıntılarına birebir erişilememiştir. Haber metinlerinin temizlenmesi, özel karakterlerin işlenmesi, maksimum token uzunluğu, truncation stratejisi ve etiket işleme adımları gibi farklılıklar sonuçların değişmesine neden olabilir.

Üçüncü olarak, hiperparametreler ve eğitim stratejileri birebir aynı olmayabilir. Bu çalışmada yaygın kullanılan değerler tercih edilmiştir: 3 epoch, $2e-5$ learning rate, 512 max token length, AdamW optimizer ve validation F1-score'a göre model seçimi. Ancak orijinal çalışmada kullanılan batch size, seed, early stopping, cross-validation, optimizer ayarları veya regularization stratejileri farklı olabilir.

Dördüncü olarak, donanım farkı önemli bir sınırlılıktır. Bu çalışmadaki deneyler NVIDIA GeForce RTX 3070 Ti Laptop GPU ve 8 GB GPU memory ile gerçekleştirilmiştir. Sınırlı VRAM nedeniyle özellikle daha büyük modellerde batch size düşük tutulmuştur. Orijinal çalışmadaki daha güçlü donanım veya cluster ortamı, daha büyük batch size, daha kapsamlı hiperparametre araması veya daha stabil eğitim süreci sağlamış olabilir.

Son olarak, class imbalance problemi bu çalışmada performansı belirgin biçimde etkilemiştir. Özellikle minority class için recall artırılmaya çalışıldığında precision değerinde düşüş görülmüştür. Bu durum, orijinal çalışmadaki veri işleme, sampling veya balancing stratejilerinin farklı olabileceğini düşündürmektedir.

5.6 Genel Değerlendirme

Bu çalışmada uygulanan geliştirme stratejileri test F1-score bakımından baseline sonucunu geçememiştir. Ancak bu durum, deneylerin başarısız olduğu anlamına gelmemektedir. Aksine, her deney model davranışına ilişkin farklı bir bilgi sağlamıştır. Weighted loss yaklaşımları recall değerini artırmış, BERT-base accuracy ve precision değerlerini yükseltmiş, learning rate düşürme recall üzerinde sınırlı bir iyileşme sağlamış, threshold tuning ise validation performansına göre karar eşiği optimizasyonunun test genellemesine sınırlı katkı sunduğunu göstermiştir.

Bu nedenle çalışmanın temel bulgusu, tek bir modelin veya tek bir hiperparametre değişikliğinin problemi çözmeye yetmediğidir. GPT-labeled fake news classification görevinde model performansı; veri seti dengesi, etiket kalitesi, preprocessing adımları, model mimarisi ve eğitim konfigürasyonu arasındaki etkileşimle belirlenmektedir. Bu açıdan çalışma, yeniden üretim ve geliştirme deneylerinin yalnızca daha yüksek skor elde etmek için değil, model davranışını anlamak için de değerli olduğunu göstermektedir.

6. Conclusion (Sonuç)

Bu çalışmada, GPT-etiketli fake news classification problemi için BERT-like transformer modelleri kullanılarak yeniden üretim ve geliştirme odaklı deneysel bir analiz gerçekleştirilmiştir. Çalışma, Raza, Paulen-Patterson ve Ding tarafından önerilen fake news detection yaklaşımını temel almış; erişilen newsmidiabias/NELA-GT_GPT-Labels_Dataset veri seti üzerinde DistilBERT, RoBERTa, BERT-base ve weighted loss tabanlı farklı model varyantları değerlendirilmiştir.

İlk deneylerde, DistilBERT baseline modeli test F1-score bakımından en güçlü sonucu üretmiştir. RoBERTa modeli daha yüksek precision değerine ulaşmasına rağmen düşük recall nedeniyle genel performansta geride kalmıştır. Weighted loss yaklaşımı ise minority class örneklerini daha iyi yakalayarak recall değerini artırmış, ancak precision ve accuracy üzerinde düşüşe neden olmuştur. Bu sonuç, veri setinde belirgin bir precision-recall tradeoff bulunduğunu göstermiştir.

Model performansını geliştirmek amacıyla threshold tuning, mild weighted loss, epoch artırma, learning rate düşürme ve BERT-base architecture comparison deneyleri uygulanmıştır. Bu deneyler farklı metriklerde iyileşme sağlamış olsa da, test F1-score bakımından DistilBERT baseline sonucunu aşamamıştır. En yüksek test accuracy ve precision değerleri BERT-base modelinde elde edilirken, en yüksek test recall değeri aggressive weighted loss yaklaşımı ile elde edilmiştir. Buna karşılık en yüksek test F1-score değeri DistilBERT baseline modelinde kalmıştır.

Bu bulgular, GPT-labeled fake news classification probleminde performansın yalnızca model mimarisine bağlı olmadığını göstermektedir. Class imbalance, threshold selection, training configuration, preprocessing kararları ve donanım sınırlamaları model davranışı üzerinde doğrudan etkili olmaktadır. Orijinal çalışmada raporlanan performans düzeylerine ulaşamamasının olası nedenleri arasında veri seti sürümü, örnek sayısı, veri işleme farklılıkları, tam hiperparametre bilgilerinin sınırlı erişilebilirliği ve deney ortamı farkları bulunmaktadır.

Sonuç olarak bu çalışma, fake news detection görevinde yeniden üretim deneylerinin yalnızca önceki sonuçları tekrar elde etmeye yönelik olmadığını; aynı zamanda modelin hangi koşullarda güçlü veya zayıf davrandığını anlamak açısından da değerli olduğunu göstermektedir. Gelecek çalışmalarda daha kapsamlı hiperparametre araması, farklı sampling stratejileri, focal loss, veri artırma yöntemleri ve daha ayrıntılı error analysis uygulanarak özellikle minority class performansının daha dengeli biçimde iyileştirilmesi hedeflenebilir.

7. Kaynakça

[1] Shu, K., Sliva, A., Wang, S., Tang, J., & Liu, H. (2017). Fake news detection on social media: A data mining perspective. *ACM SIGKDD Explorations Newsletter*, 19(1), 22-36. <https://doi.org/10.1145/3137597.3137600>

- [2] Zhou, X., & Zafarani, R. (2020). A survey of fake news: Fundamental theories, detection methods, and opportunities. *ACM Computing Surveys*, 53(5), Article 109. <https://doi.org/10.1145/3395046>
- [3] Rashkin, H., Choi, E., Jang, J. Y., Volkova, S., & Choi, Y. (2017). Truth of varying shades: Analyzing language in fake news and political fact-checking. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing* (pp. 2931–2937). Association for Computational Linguistics. <https://doi.org/10.18653/v1/D17-1317>
- [4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, 30.
- [5] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT 2019* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>
- [6] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*.
- [7] Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*.
- [8] Kaliyar, R. K., Goswami, A., & Narang, P. (2021). FakeBERT: Fake news detection in social media with a BERT-based deep learning approach. *Multimedia Tools and Applications*, 80, 11765–11788. <https://doi.org/10.1007/s11042-020-10183-2>
- [9] Azizah, S. F. N., Cahyono, H. D., Sihwi, S. W., & Widiarto, W. (2023). Performance analysis of transformer based models (BERT, ALBERT and RoBERTa) in fake news detection. *arXiv preprint arXiv:2308.04950*.
- [10] Shu, K., Mahudeswaran, D., Wang, S., Lee, D., & Liu, H. (2020). FakeNewsNet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media. *Big Data*, 8(3), 171–188. <https://doi.org/10.1089/big.2020.0062>
- [11] Nørregaard, J., Horne, B. D., & Adalı, S. (2019). NELA-GT-2018: A large multi-labelled news dataset for the study of misinformation in news articles. In *Proceedings of the International AAAI Conference on Web and Social Media*, 13(1), 630–638.
- [12] Gruppi, M., Horne, B. D., & Adalı, S. (2022). NELA-GT-2022: A large multi-labelled news dataset for the study of misinformation in news articles. *arXiv preprint arXiv:2203.05659*.
- [13] Raza, S., Paulen-Patterson, D., & Ding, C. (2025). Fake news detection: Comparative evaluation of BERT-like models and large language models with generative AI-annotated data. *Knowledge and Information Systems*, 67, 3267–3292. <https://doi.org/10.1007/s10115-024-02321-1>
- [14] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. (2020). Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, 33, 1877–1901.

- [15] Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., et al. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*.
- [16] Jiang, A. Q., Sablayrolles, A., Mensch, A., Bamford, C., Chaplot, D. S., Casas, D., Bressand, F., Lengyel, G., Lample, G., Saulnier, L., et al. (2023). Mistral 7B. *arXiv preprint arXiv:2310.06825*.
- [17] OpenAI. (2023). GPT-4 technical report. *arXiv preprint arXiv:2303.08774*.
- [18] Bang, Y., Cahyawijaya, S., Lee, N., Dai, W., Su, D., Wilie, B., Lovenia, H., Ji, Z., Yu, T., Chung, W., et al. (2023). A multitask, multilingual, multimodal evaluation of ChatGPT on reasoning, hallucination, and interactivity. *arXiv preprint arXiv:2302.04023*.
- [19] Hu, B., Sheng, Q., Cao, J., Shi, Y., Li, Y., Wang, D., & Qi, P. (2024). Bad actor, good advisor: Exploring the role of large language models in fake news detection. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(20), 22105–22113. <https://doi.org/10.1609/aaai.v38i20.30214>
- [20] Mintz, M., Bills, S., Snow, R., & Jurafsky, D. (2009). Distant supervision for relation extraction without labeled data. In *Proceedings of ACL-IJCNLP 2009* (pp. 1003-1011). Association for Computational Linguistics.
- [21] Gilardi, F., Alizadeh, M., & Kubli, M. (2023). ChatGPT outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30), e2305016120. <https://doi.org/10.1073/pnas.2305016120>
- [22] Wang, S., Liu, Y., Xu, Y., Zhu, C., & Zeng, M. (2021). Want to reduce labeling cost? GPT-3 can help. In *Findings of the Association for Computational Linguistics: EMNLP 2021* (pp. 4195-4205).
- [23] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), Article 248. <https://doi.org/10.1145/3571730>
- [24] Motoki, F., Neto, V. P., & Rodrigues, V. (2024). More human than human: Measuring ChatGPT political bias. *Public Choice*, 198, 3-23. <https://doi.org/10.1007/s11127-023-01097-2>
- [25] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263-1284. <https://doi.org/10.1109/TKDE.2008.239>
- [26] Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. *Journal of Big Data*, 6, Article 27. <https://doi.org/10.1186/s40537-019-0192-5>
- [27] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- [28] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollar, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2980-2988).

- [29] Cui, Y., Jia, M., Lin, T.-Y., Song, Y., & Belongie, S. (2019). Class-balanced loss based on effective number of samples. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 9268-9277). <https://doi.org/10.1109/CVPR.2019.00949>
- [30] Madabushi, H. T., Kochkina, E., & Castelle, M. (2020). Cost-sensitive BERT for generalisable sentence classification with imbalanced data. In *Proceedings of the 3rd Workshop on NLP for Internet Freedom: Censorship, Disinformation, and Propaganda*. arXiv:2003.11563
- [31] Henning, S., Beluch, W., Fraser, A., & Friedrich, A. (2023). A survey of methods for addressing class imbalance in deep-learning based natural language processing. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics* (pp. 523–540). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.eacl-main.38>
- [32] Esposito, C., Landrum, G. A., Schneider, N., Stiefl, N., & Riniker, S. (2021). GHOST: Adjusting the decision threshold to handle imbalanced data in machine learning. *Journal of Chemical Information and Modeling*, 61(6), 2623-2640. <https://doi.org/10.1021/acs.jcim.1c00160>

Ek A. Kod Deposu

Bu çalışmada kullanılan kodlar, deney çıktıları ve grafikler aşağıdaki GitHub reposunda düzenlenmiştir:

<https://github.com/gencnis/fake-news-bert-reproduction>