

# MAKALE TABANLI YÖNTEM YENİDEN ÜRETİMİ VE KARŞILAŞTIRMALI DENEY RAPORU

## Fake News Detection: BERT-like Modeller ve LLM Karşılaştırması

Örüntü Tanıma ve Uygulamaları Dersi - 2. Aşama Ödevi

### 1. Makale Bilgileri

|                  |                                                                                                                                         |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
| Makale Adı       | Fake News Detection: Comparative Evaluation of BERT-like Models and Large Language Models with Generative AI-Annotated Data             |
| Yazarlar         | Shaina Raza; Draï Paulen-Patterson; Chen Ding                                                                                           |
| Yayın Yılı       | 2025 (Knowledge and Information Systems, Published: 05 January 2025)                                                                    |
| Yayın Yeri       | Knowledge and Information Systems (Springer), Cilt 67, sayfa 3267–3292                                                                  |
| Dergi DOI        | 10.1007/s10115-024-02321-1                                                                                                              |
| arXiv DOI        | 10.48550/arXiv.2412.14276                                                                                                               |
| Lisans (arXiv)   | CC BY 4.0 - <a href="https://creativecommons.org/licenses/by/4.0/">https://creativecommons.org/licenses/by/4.0/</a>                     |
| Makale Sayfası   | <a href="https://arxiv.org/abs/2412.14276">https://arxiv.org/abs/2412.14276</a>                                                         |
| PDF Linki        | <a href="https://arxiv.org/pdf/2412.14276">https://arxiv.org/pdf/2412.14276</a>                                                         |
| Springer Sayfası | <a href="https://link.springer.com/article/10.1007/s10115-024-02321-1">https://link.springer.com/article/10.1007/s10115-024-02321-1</a> |
| Kod Reposu       | <a href="https://github.com/draip96/FakeNewsClassification">https://github.com/draip96/FakeNewsClassification</a>                       |

### 2. Amaç

Bu çalışmanın amacı, seçilen bilimsel makalede önerilen **fake news detection** yaklaşımını yerel bir ortamda yeniden üretmek (reproduction) ve elde edilen sonuçları makaledeki bulgular ile karşılaştırmalı olarak analiz etmektir.

Bu kapsamda çalışmada aşağıdaki hedefler belirlenmiştir:

- Makalede kullanılan veri setine, yazarların paylaştığı GitHub reposu üzerinden erişmek ve veri setini indirerek kullanıma hazırlamak
- Makalede önerilen **BERT-like model tabanlı sınıflandırma yaklaşımını** mümkün olduğunca aynı metodoloji ile uygulamak
- Elde edilen modeli eğiterek makaledeki performans metriklerini (**accuracy, precision, recall, F1-score**) yeniden üretmeye çalışmak
- Farklı model varyantları (**DistilBERT, RoBERTa**) ve ek iyileştirme yöntemleri (**weighted loss**) kullanarak performans karşılaştırması yapmak

- Elde edilen sonuçları makaledeki sonuçlarla karşılaştırarak farkların nedenlerini analiz etmek

Bu çalışma aynı zamanda, **class imbalance probleminin** model performansı üzerindeki etkisini incelemeyi ve bu probleme yönelik çözüm yaklaşımlarının (örneğin weighted loss) performans üzerindeki etkisini değerlendirmeyi amaçlamaktadır.

Sonuç olarak, bu rapor yalnızca bir yeniden üretim (reproduction) çalışması değil, aynı zamanda elde edilen sonuçların eleştirel bir bakış açısıyla değerlendirilmesini ve makaledeki yöntemlerin pratik uygulanabilirliğinin analiz edilmesini hedeflemektedir.

### 3. Problem Tanımı

---

Bu çalışmada ele alınan temel problem, verilen bir haber metninin **gerçek (real)** veya **sahte (fake)** olup olmadığının otomatik olarak belirlenmesidir. Bu problem, doğal dil işleme (**Natural Language Processing - NLP**) alanında bir **binary text classification** problemi olarak tanımlanmaktadır.

İncelenen makalede, bu problem yalnızca klasik sınıflandırma perspektifiyle ele alınmamış, aynı zamanda **Generative AI (GPT) ile oluşturulan etiketlerin (gpt label)** veri kalitesi ve model performansı üzerindeki etkisi de araştırılmıştır. Bu bağlamda, veri setinde iki farklı etiket türü bulunmaktadır:

- **nela label:** Geleneksel yöntemlerle oluşturulmuş doğruluk etiketi
- **gpt label:** Generative AI kullanılarak üretilmiş etiket

Bu çalışmada, makalenin ana yaklaşımı doğrultusunda hedef değişken olarak **gpt label** kullanılmıştır.

Problem, aşağıdaki zorlukları içermektedir:

- **Uzun ve kompleks metinler:** Haber içerikleri yüksek uzunluk ve bağlamsal karmaşıklık içermektedir
- **Dilsel belirsizlik:** Fake news içerikleri çoğu zaman gerçek haber diline benzer şekilde yazılmaktadır
- **Class imbalance:** Veri setinde sınıflar arasında belirgin bir dengesizlik bulunmaktadır (özellikle gpt label dağılımında)
- **Genelleme problemi:** Modelin farklı haber türleri ve içeriklerde doğru tahmin yapabilmesi gerekmektedir

Bu problemin çözümü için makalede **BERT-like transformer modelleri** (örneğin BERT, RoBERTa, DistilBERT) ve **Large Language Models (LLMs)** karşılaştırmalı olarak değerlendirilmiştir.

Bu çalışma kapsamında ise problem şu şekilde yeniden formüle edilmiştir:

“Verilen bir haber başlığı (**title**) ve içerik (**content**) kullanılarak, ilgili haberin **gpt label** etiketine göre doğru sınıfa atanması”

Bu problem tanımı doğrultusunda, farklı model mimarileri ve eğitim stratejileri kullanılarak model performansı değerlendirilmiş ve elde edilen sonuçlar makaledeki bulgular ile karşılaştırılmıştır.

## 4. Kullanılan Veri Seti

---

Bu çalışmada kullanılan veri seti, seçilen makalenin yazarları tarafından paylaşılan GitHub reposu üzerinden erişilen veri kaynaklarına dayanmaktadır. İlgili repo aracılığıyla yönlendirme yapılarak, Hugging Face platformunda yer alan **newsmediabias/NELA-GT\_GPT-Labels\_Dataset** veri seti kullanılmıştır.

Veri seti, haber metinlerinden oluşan ve her bir örnek için farklı etiket türleri içeren bir yapıya sahiptir. Erişilen veri seti sürümü aşağıdaki özelliklere sahiptir:

- Toplam örnek sayısı: **5414**
- Veri türü: **Metin (text)**
- Veri alanları:
  - **title**: Haber başlığı
  - **content**: Haber içeriği
  - **nela label**: Geleneksel yöntemlerle oluşturulmuş etiket
  - **gpt label**: Generative AI (GPT) kullanılarak oluşturulmuş etiket

Bu çalışmada, makalenin ana yaklaşımı doğrultusunda hedef değişken olarak **gpt label** kullanılmıştır.

### 4.1 Veri Seti Kaynağı ve Erişim Notu

Makaledeki orijinal veri setine birebir erişim mümkün olmamış, bunun yerine yazarların paylaştığı GitHub reposu üzerinden yönlendirilen veri setinin Hugging Face üzerindeki sürümü kullanılmıştır. Bu durum, elde edilen sonuçların makaledeki sonuçlar ile birebir örtüşmemesine neden olabilecek önemli bir faktör olarak değerlendirilmiştir.

### 4.2 Veri Ön İşleme (Preprocessing)

Veri seti üzerinde aşağıdaki ön işleme adımları uygulanmıştır:

- Eksik veri kontrolü yapılmış ve veri setinde eksik değer bulunmadığı gözlemlenmiştir
- Model girişine uygun hale getirmek amacıyla **title** ve **content** alanları birleştirilmiştir
- Maksimum giriş uzunluğu **512 token** olacak şekilde tokenization uygulanmıştır
- Transformer modellerine uygun formatta giriş tensörleri (**input\_ids**, **attention\_mask**) oluşturulmuştur

### 4.3 Veri Bölme

Veri seti, deneylerin yeniden üretilebilirliğini sağlamak amacıyla aşağıdaki şekilde yeniden bölünmüştür:

- %80 **train**
- %10 **validation**
- %10 **test**

Bölme işlemi sırasında **stratified split** yöntemi kullanılarak sınıf dağılımının korunması sağlanmıştır.

### 4.4 Sınıf Dağılımı

Veri setinde hedef değişken olan **gpt label** için sınıf dağılımı aşağıdaki gibidir:

- Sınıf 0: **4429 örnek**

- Sınıf 1: **985 örnek**

Bu dağılım, veri setinde belirgin bir **class imbalance** problemi olduğunu göstermektedir. Bu durum, model performansını özellikle **recall** ve **F1-score** açısından doğrudan etkilemektedir.

## 5. Uygulanan Yöntem

---

Bu çalışmada, seçilen makalede önerilen yaklaşım temel alınarak **BERT-like transformer modelleri** kullanılarak bir **text classification pipeline** oluşturulmuştur. Amaç, haber metinlerinden **gpt label** etiketini tahmin eden bir model geliştirmek ve makaledeki sonuçları yeniden üretmeye çalışmaktır.

### 5.1 Model Mimarileri

Çalışma kapsamında aşağıdaki model varyantları kullanılmıştır:

- **DistilBERT (distilbert-base-uncased)**  
Daha hafif ve hızlı bir transformer modeli olup, baseline model olarak kullanılmıştır.
- **RoBERTa (roberta-base)**  
BERT modelinin geliştirilmiş bir versiyonu olup, daha güçlü temsil yeteneğine sahiptir.
- **DistilBERT (Weighted Loss ile)**  
Class imbalance problemini azaltmak amacıyla, kayıp fonksiyonuna sınıf ağırlıkları eklenerek eğitilmiştir.

### 5.2 Girdi Temsili

Model girişleri, veri setindeki iki metin alanının birleştirilmesi ile oluşturulmuştur:

- **title + content**

Bu yaklaşım, haberin hem başlık hem de içerik bilgisini birlikte kullanarak daha güçlü bir bağlamsal temsil elde etmeyi amaçlamaktadır.

Tokenization işlemi için ilgili modelin tokenizer'ı kullanılmış ve:

- Maksimum uzunluk: **512 token**
- Padding: **max\_length**
- Truncation: **aktif**

olarak ayarlanmıştır.

### 5.3 Eğitim Yapılandırması

Tüm modeller aşağıdaki temel eğitim ayarları ile eğitilmiştir:

- Epoch sayısı: **3**
- Learning rate: **2e-5**
- Optimizer: **AdamW (default Trainer)**
- Weight decay: **0.01**
- Evaluation strategy: **epoch bazlı**
- Model selection: **validation F1-score'a göre en iyi model**

Batch size değerleri modele göre değişmiştir:

- DistilBERT: 8
- RoBERTa: 4 (VRAM sınırlamaları nedeniyle)

## 5.4 Değerlendirme Metrikleri

Model performansı aşağıdaki metrikler kullanılarak değerlendirilmiştir:

- Accuracy
- Precision
- Recall
- F1-score

Bu metrikler, özellikle class imbalance bulunan veri setlerinde model performansını daha doğru analiz edebilmek için birlikte değerlendirilmiştir.

## 5.5 Class Imbalance ve Weighted Loss

Veri setinde bulunan sınıf dengesizliği nedeniyle, modelin minority class (sınıf 1) üzerinde düşük performans göstermesi beklenmektedir. Bu durumu iyileştirmek amacıyla, DistilBERT modeli için **weighted loss** yaklaşımı uygulanmıştır.

Sınıf ağırlıkları aşağıdaki şekilde hesaplanmıştır:

- Class 0 ağırlığı: 1.22
- Class 1 ağırlığı: 5.49

Bu ağırlıklar, veri setindeki sınıf frekanslarına ters orantılı olacak şekilde belirlenmiş ve **CrossEntropyLoss** fonksiyonuna entegre edilmiştir.

Bu sayede modelin minority class örneklerine daha fazla önem vermesi sağlanmıştır.

## 6. Deneysel Sonuçlar

Bu bölümde, uygulanan model varyantlarından elde edilen sonuçlar sunulmakta ve karşılaştırmalı olarak analiz edilmektedir.

### 6.1 Model Performans Karşılaştırması

Aşağıdaki tabloda, farklı model yaklaşımlarının validation ve test setleri üzerindeki performansları verilmiştir:

| Model                 | Val Accuracy | Val Precision | Val Recall | Val F1 | Test Accuracy | Test Precision | Test Recall | Test F1 |
|-----------------------|--------------|---------------|------------|--------|---------------|----------------|-------------|---------|
| DistilBERT            | 0.8651       | 0.7119        | 0.4286     | 0.5350 | 0.8708        | 0.7302         | 0.4646      | 0.5679  |
| RoBERTa               | 0.8484       | 0.7222        | 0.2653     | 0.3881 | 0.8598        | 0.7949         | 0.3131      | 0.4493  |
| DistilBERT (Weighted) | 0.8429       | 0.5596        | 0.6224     | 0.5894 | 0.8173        | 0.5000         | 0.6465      | 0.5639  |

Tablo 1: Modellerin Validation ve Test Setleri Üzerindeki Performans Karşılaştırması

### 6.2 Sonuçların Analizi

Elde edilen sonuçlar incelendiğinde aşağıdaki bulgular öne çıkmaktadır:

### 6.2.1 DistilBERT (Baseline)

DistilBERT modeli, genel performans açısından en dengeli sonuçları vermiştir. Test setinde:

- **Accuracy:** 0.8708
- **F1-score:** 0.5679

değerlerine ulaşarak en yüksek test F1 skorunu elde etmiştir.

Bu durum, daha hafif bir model olmasına rağmen DistilBERT'in bu veri seti ve görev için oldukça uygun bir baseline model olduğunu göstermektedir.

### 6.2.2 RoBERTa

RoBERTa modeli, precision açısından daha yüksek değerler üretmiştir:

- Test Precision: **0.7949**

Ancak, recall değerinin oldukça düşük olması:

- Test Recall: **0.3131**

modelin minority class örneklerini yeterince yakalayamadığını göstermektedir. Bu nedenle F1-score değeri düşmüş ve model genel performans açısından DistilBERT'in gerisinde kalmıştır.

Bu durum, daha güçlü model mimarisinin her zaman daha iyi sonuç vermediğini ve veri seti özelliklerinin model performansı üzerinde kritik rol oynadığını göstermektedir.

### 6.2.3 DistilBERT (Weighted Loss)

Weighted loss kullanılan modelde, class imbalance problemine yönelik iyileştirme hedeflenmiştir.

Bu modelde:

- Test Recall: **0.6465** (önemli artış)
- Test Precision: **0.5000** (düşüş)

gözlemlenmiştir.

Bu durum, modelin minority class örneklerini daha iyi yakalayabildiğini ancak daha fazla **false positive** ürettiğini göstermektedir.

F1-score değeri:

- **0.5639**

olup, baseline model ile benzer seviyede kalmıştır.

## 6.3 Genel Değerlendirme

Sonuçlar birlikte değerlendirildiğinde:

- **DistilBERT baseline**, en dengeli performansı sunmuştur
- **RoBERTa**, yüksek precision ancak düşük recall nedeniyle zayıf performans göstermiştir
- **Weighted loss yaklaşımı**, recall değerini artırmış ancak precision ve accuracy üzerinde olumsuz etki yaratmıştır

Bu sonuçlar, veri setindeki **class imbalance** probleminin model performansı üzerinde doğrudan etkili olduğunu açıkça göstermektedir.

## 7. Makale ile Karşılaştırma ve Tartışma

Bu çalışmada elde edilen sonuçlar, seçilen makaledeki bulgular ile karşılaştırmalı olarak değerlendirilmiştir. Amaç, uygulanan yöntemin ne ölçüde yeniden üretilebildiğini analiz etmek ve ortaya çıkan farkların nedenlerini açıklamaktır.

### 7.1 Makale ile Sonuç Karşılaştırması

İncelenen makalede, BERT-like modellerin ve özellikle daha güçlü transformer mimarilerinin yüksek performans elde ettiği raporlanmıştır. Ancak bu çalışmada elde edilen sonuçlar, makaledeki performans değerleri ile birebir örtüşmemektedir.

Bu çalışmada elde edilen bulgular şu şekildedir:

- **DistilBERT modeli**, genel performans açısından en dengeli sonuçları vermiştir
- **RoBERTa modeli**, beklenenin aksine düşük recall nedeniyle daha düşük F1-score üretmiştir
- **Weighted loss yaklaşımı**, recall değerini artırmış ancak genel performansı sınırlı ölçüde iyileştirmiştir

Makale ile bu çalışmanın sonuçları aşağıdaki tabloda karşılaştırmalı olarak sunulmuştur:

| Model      | Makale F1 (%) | Bu Çalışma F1 (%) |
|------------|---------------|-------------------|
| DistilBERT | 84.08         | 56.79             |
| RoBERTa    | 89.68         | 44.93             |

Tablo 2: Makale ve Bu Çalışmanın F1-score Karşılaştırması

Makaledeki sonuçlar ile bu çalışmada elde edilen sonuçlar arasında ciddi bir performans farkı gözlemlenmiştir. Özellikle RoBERTa modelinde F1-score'un ~89 seviyesinden ~0.44 seviyesine düşmesi, veri seti ve deney ortamı farklılıklarının model performansı üzerindeki etkisini açıkça göstermektedir.

### 7.2 Farklılıkların Olası Nedenleri

#### 7.2.1 Veri Seti Farklılıkları

Makaledeki orijinal veri setine birebir erişim sağlanamamış, bunun yerine yazarların GitHub deposu üzerinden yönlendirilmiş Hugging Face veri seti kullanılmıştır.

Bu veri seti:

- Daha küçük örnek sayısına sahiptir (**5414 örnek**)
- Tek bir split olarak sunulmaktadır

- Farklı bir veri işleme sürecinden geçmiş olabilir

Bu durum, model performansının makaledeki sonuçlardan farklı olmasının en önemli nedenlerinden biridir.

### 7.2.2 Donanım ve Eğitim Ortamı

Makaledeki deneylerin yüksek performanslı GPU veya cluster ortamlarında gerçekleştirildiği değerlendirilmektedir. Bu çalışmada ise:

- **RTX 3070 Ti Laptop GPU**
- Sınırlı VRAM kapasitesi
- Daha küçük batch size değerleri

kullanılmıştır.

Bu durum, modelin öğrenme kapasitesini ve genelleme performansını doğrudan etkilemiş olabilir.

### 7.2.3 Model ve Hiperparametre Farklılıkları

Makaledeki modellerin tam hiperparametre ayarları ve eğitim detayları birebir olarak sağlanmamıştır. Bu nedenle:

- Epoch sayısı
- Learning rate
- Batch size
- Regularization ayarları

gibi parametreler literatürde yaygın kullanılan değerler üzerinden belirlenmiştir.

Bu farklılıklar da sonuçların birebir örtüşmemesine neden olabilir.

### 7.2.4 Class Imbalance Etkisi

Veri setinde gözlemlenen belirgin **class imbalance** durumu, model performansı üzerinde doğrudan etkili olmuştur.

Bu çalışmada:

- Baseline model minority class'ı yakalamakta zorlanmış
- Weighted loss ile recall artırılmış
- Ancak precision ve accuracy üzerinde düşüş gözlemlenmiştir

Bu durum, model performansında **precision-recall tradeoff** oluştuğunu göstermektedir.

## 7.3 Genel Tartışma

Elde edilen sonuçlar, makaledeki yöntemin genel olarak uygulanabilir olduğunu göstermektedir. Ancak:

- Veri seti farklılıkları
- Donanım sınırlamaları



- Eğitim parametreleri

gibi faktörler nedeniyle birebir sonuç üretimi mümkün olmamıştır.

Buna rağmen, çalışma kapsamında:

- Model pipeline başarıyla kurulmuş
- Farklı model varyantları karşılaştırılmış
- Class imbalance problemi analiz edilmiş

ve makaledeki yaklaşımın temel davranışları gözlemlenebilmiştir.

## 8. Sonuç

---

Bu çalışmada, seçilen bilimsel makalede önerilen fake news detection yaklaşımı yerel bir ortamda yeniden uygulanmış ve elde edilen sonuçlar makaledeki bulgular ile karşılaştırmalı olarak analiz edilmiştir.

Çalışma kapsamında:

- Makalede referans verilen veri setine GitHub deposu üzerinden erişilmiş
- Veri seti yeniden yapılandırılarak **train/validation/test split** oluşturulmuş
- Farklı transformer tabanlı modeller (**DistilBERT, RoBERTa**) uygulanmış
- Class imbalance problemini ele almak amacıyla **weighted loss** yaklaşımı test edilmiştir

Elde edilen sonuçlar, DistilBERT modelinin bu veri seti için en dengeli performansı sunduğunu göstermiştir. RoBERTa modeli daha yüksek precision değerleri üretmesine rağmen düşük recall nedeniyle genel performansta geride kalmıştır. Weighted loss yaklaşımı ise minority class üzerindeki başarıyı artırmış, ancak precision ve accuracy üzerinde olumsuz etkiler oluşturmuştur.

Bu bulgular, veri setindeki **class imbalance probleminin** model performansı üzerinde kritik bir rol oynadığını ve model seçiminden bağımsız olarak dikkate alınması gerektiğini göstermektedir.

Makaledeki sonuçlar ile birebir örtüşmeyen performans değerleri; veri seti farklılıkları, donanım sınırlamaları ve hiperparametre ayarları gibi faktörler ile açıklanmıştır.

Sonuç olarak, bu çalışma kapsamında makaledeki yöntem başarıyla yeniden uygulanmış, elde edilen sonuçlar analiz edilmiş ve model performansını etkileyen temel faktörler ortaya konmuştur. Ayrıca, elde edilen bulgular doğrultusunda gelecekte yapılacak çalışmalar için **class imbalance handling** yöntemlerinin daha detaylı incelenmesi önerilmektedir.

— Rapor Sonu —